

Modélisation des Sinistres en Assurance Automobile

Étude exploratoire, nettoyage, structuration et modélisation
d'un portefeuille télématique synthétique (100 000 contrats)

100 000	52	4,3 %	Phases 1–7
contrats analysés	variables	taux de sinistres	de modélisation

Auteurs : Fatoumata / Rami / Eunice
Date : Mai 2026

Table des matières

1	Résumé Exécutif	4
2	Contexte et Objectifs du Projet	5
2.1	Cadre actuariel : la prime pure	5
2.2	Usage-Based Insurance (UBI)	6
2.2.1	Principe général	6
2.2.2	Avantages par rapport à la tarification classique	6
2.3	Objectifs du projet	6
3	Présentation du Jeu de Données	6
3.1	Vue d'ensemble	7
3.2	Dictionnaire des variables traditionnelles	7
3.3	Variables cibles	8
3.4	Variables télématicques	8
4	Qualité et Nettoyage des Données	8
4.1	Contrôles initiaux	8
4.2	Traitement des incohérences univariées	9
4.2.1	Variable <code>Duration</code> — Durée de couverture	9
4.2.2	Variable <code>Age</code> — Âge de l'assuré	9
4.2.3	Variable <code>Car_age</code> — Âge du véhicule	9
4.3	Traitement des incohérences multivariées	10
4.3.1	Contrôle <code>Age / Years_noclaims</code>	10
4.3.2	Variable <code>AMT_Claim</code> — Montant de sinistre nul pour sinistre déclaré	10
4.4	Bilan synthétique du nettoyage	11
5	Analyse Exploratoire des Données	11
5.1	Distribution du nombre de sinistres (<code>NB_Claim</code>)	11
5.2	Profil conducteur selon le statut sinistre	12
5.3	Score de crédit et sinistralité	13
5.4	Kilométrage et exposition au risque	14
5.5	Relation non linéaire entre kilométrage et sinistralité	15
5.6	Matrice de corrélation — Variables traditionnelles	16
5.7	Comportement d'accélération selon le statut sinistre	16
5.8	Comportement temporel de conduite	17
6	Feature Engineering	17
6.1	Variable <code>Exposure</code> — Fraction d'année couverte	18
6.2	Variable <code>Expected_miles</code> — Kilométrage attendu	18
6.3	Variable <code>mileage_ratio</code> — Ratio kilométrage réel/attendu	18
7	Pipeline de Traitement des Données	19
8	Modélisation — Prédiction de la Sinistralité	19
8.1	Phase 1 — Préparation pour la modélisation	19
8.1.1	Définition de la variable cible binaire <code>has_claim</code>	19
8.1.2	Gestion de la colinéarité compositionnelle	20

8.1.3	Exclusion de variables dérivées redondantes	20
8.1.4	Définition des de features	21
8.1.5	Split train / validation / test stratifié	21
8.1.6	Pipelines de prétraitement	21
8.2	Phase 2 — Modèles baselines	22
8.2.1	Modèle 1 — Régression logistique sur variables traditionnelles	22
8.2.2	Modèle 2 — Régression logistique sur traditionnel + télématique	23
8.2.3	Modèle 3 — XGBoost sur ensemble complet	23
8.2.4	Courbes ROC comparées	24
8.2.5	Importance des variables — XGBoost	25
8.2.6	Tableau récapitulatif Phase 2	26
8.3	Phase 3 — Traitement du déséquilibre	26
8.3.1	Motivation	26
8.3.2	SMOTE — Principe et variante U-shape	27
8.3.3	Plan d'expérience factoriel 2×3	28
8.3.4	Datasets rééchantillonnés	28
8.3.5	Résultats — Variants LR	29
8.3.6	Résultats — Variants XGBoost	30
8.3.7	Vue synthétique du plan d'expérience	31
8.3.8	Tableau récapitulatif Phase 3	31
8.3.9	Conclusions Phase 3	31
8.3.10	Sélection des modèles pour l'évaluation finale (Phase 4)	32
9	Phase 4 — Évaluation finale sur le test set	32
9.1	Protocole d'évaluation	32
9.1.1	Modèles évalués	33
9.1.2	Métriques et protocole	33
9.2	Seuils G-mean optimaux mesurés sur la validation	33
9.3	Résultats sur le test set	34
9.4	Intervalles de confiance bootstrap (95 %, 1 000 rééchantillonnages)	35
9.5	Comparaison validation vs test — Généralisation	35
9.6	Analyse de calibration des modèles XGBoost	36
9.6.1	Motivation — Ranking vs calibration	36
9.6.2	Trois métriques de calibration	36
9.6.3	Résultats de calibration	36
9.6.4	Diagrammes de fiabilité — XGBoost baseline vs cost-weighted	37
9.6.5	Distribution des probabilités prédites par classe	38
9.7	Synthèse Phase 4 — Conclusions	38
10	Phase 5 — Calibration post-hoc (extension méthodologique)	39
10.1	Motivation et objectif	39
10.2	Deux méthodes de calibration testées	39
10.2.1	Platt scaling	39
10.2.2	Isotonic regression	39
10.3	Comparaison des 4 variants de calibration sur le test set	40
10.4	Diagrammes de fiabilité — 4 variants	40
10.5	Distribution des probabilités avant et après calibration	41
10.6	Tableau de synthèse Phase 5	42
10.7	Recommandation finale opérationnelle	42

11 Phase 6 — Modèles Fréquence × Sévérité Actuariels (extension)	42
11.1 Motivation et objectifs	42
11.2 Architecture du pipeline actuariel	43
11.3 Préparation des données	43
11.4 Modèle 1 — Régression de Poisson (fréquence)	44
11.5 Modèle 2 — Régression Gamma (sévérité)	44
11.6 Prime pure — Résultat final	45
11.7 Tableau de lift — Segmentation par décile de prime pure	45
11.8 Comparaison modèle actuariel vs modèles binaires Phase 4	46
12 Phase 7 — Deep Learning : MLP (extension)	46
12.1 Motivation	46
12.2 Architecture du réseau	47
12.3 Courbes d'apprentissage	47
12.4 Résultats sur le test set	48
12.5 Comparaison finale — Tous modèles (test set)	49
12.6 Synthèse Phase 7	50
13 Conclusion Générale	50
13.1 Bilan des 7 phases	50
13.2 Recommandation opérationnelle finale	51
13.3 Limitations de l'étude	51
13.4 Perspectives et extensions	51
13.4.1 Explicabilité (XAI) — SHAP values	51
13.4.2 Deep Learning avancé — TabNet et NODE	51
13.4.3 Validation croisée et tuning Bayésien	51
13.4.4 Monitoring en production	51

1 Résumé Exécutif

Ce rapport constitue la **livraison finale** du projet de modélisation de la sinistralité en assurance automobile de type Usage-Based Insurance (UBI). Il documente l'intégralité des étapes réalisées : exploration et nettoyage des données, construction de variables dérivées (**feature engineering**), modélisation par approches progressive, évaluation finale, calibration post-hoc, modélisation actuarielle classique et deep learning.

L'objectif central du projet est de produire un **modèle de prime pure** actuariellement valide, capable de prédire la fréquence et le coût des sinistres pour chaque contrat du portefeuille, tout en quantifiant l'apport informationnel des variables télématiques par rapport aux variables de tarification classiques.

Points clés

- **Base de données** : aucune valeur manquante ni doublon détecté dans la base brute ; 5 catégories d'incohérences identifiées et corrigées de façon reproductible ($\approx 7\,600$ observations).
- **Portefeuille fortement déséquilibré** : taux de sinistres de **4,3 %**, ratio de déséquilibre de 22 pour 1, caractéristique des portefeuilles UBI réels.
- **Apport de la télématique quantifié** : +10,97 points d'AUC en ajoutant les variables télématiques aux variables traditionnelles (régression logistique).
- **XGBoost meilleur modèle de ranking** : AUC-ROC de **0,892** sur le test set, contre 0,677 pour la baseline traditionnelle — écart total de +21,5 points.
- **SMOTE non recommandé pour XGBoost** : le suréchantillonnage dégrade l'AUC de $-0,035$; le cost-weighting est préférable.
- **Calibration post-hoc résolue** : le pipeline XGBoost + cost-weighted + Platt scaling cumule AUC élevée (0,889), G-mean opérationnel (0,814) et calibration actuarielle ($ECE = 0,003$).
- **Pipeline actuariel validé** : Poisson $\times$ Gamma produit une prime pure avec ratio observé/prédit ≈ 1 et lift décile 10/décile 1 $\approx 20\text{--}30\times$.
- **MLP confirme les non-linéarités** : AUC = 0,878 sur le test set, entre XGBoost (0,892) et la régression logistique (0,778).

100 000

Contrats totaux

7 Phases

Modélisation

4,3 %Taux de
sinistres**0,892**

AUC XGBoost

Structure du rapport — 7 phases

1. **Section 2** — Contexte actuariel et objectifs du projet.
2. **Section 3** — Description du jeu de données (52 variables).
3. **Section 4** — Qualité et nettoyage (5 types d'incohérences, méthodes de correction).
4. **Section 5** — Analyse exploratoire : distributions, corrélations, comportements de conduite.
5. **Section 6** — Feature engineering : 3 variables dérivées.
6. **Section 7** — Pipeline de pré-traitement structuré en 8 étapes.
7. **Section 8** — Modélisation Phase 1 (préparation), Phase 2 (baselines), Phase 3 (traitement du déséquilibre).
8. **Section 9** — Phase 4 : évaluation finale sur le test set, intervalles de confiance bootstrap, analyse de calibration.
9. **Section 10** — Phase 5 : calibration post-hoc (Platt scaling et isotonic regression).
10. **Section 11** — Phase 6 : modèles fréquence × sévérité actuariels (Poisson + Gamma, prime pure, tableau de lift).
11. **Section 12** — Phase 7 : Deep Learning (MLP), courbes d'apprentissage, comparaison finale tous modèles.
12. **Section 13** — Conclusion et recommandations par cas d'usage.

2 Contexte et Objectifs du Projet

2.1 Cadre actuariel : la prime pure

En assurance non-vie, la **prime pure** (également appelée prime de risque ou prime technique) représente le coût espéré des sinistres qu'un assureur devra payer pour un contrat donné. Elle est distincte de la prime commerciale qui intègre également les frais de gestion, les marges de profit et les taxes.

La prime pure se décompose en deux composantes multiplicatives :

$$\text{Prime pure} = \underbrace{\mathbb{E}[\text{NB_Claim}]}_{\substack{\text{Fréquence} \\ \text{(nb moyen de sinistres)}}} \times \underbrace{\mathbb{E}[\text{AMT_Claim} \mid \text{NB_Claim} > 0]}_{\substack{\text{Sévérité} \\ \text{(coût moyen par sinistre)}}} \quad (1)$$

Cette décomposition, standard dans la pratique actuarielle, présente des avantages :

- Elle permet de modéliser séparément deux phénomènes statistiquement distincts (compter des événements vs. estimer leur coût).
- Elle facilite l'interprétation métier : un conducteur peut avoir une fréquence élevée mais des sinistres peu graves (accrochages répétés), ou au contraire peu d'accidents mais très coûteux.
- Elle correspond à la **structure des données disponibles** : la variable **NB_Claim** est un comptage (modèle de Poisson), tandis que **AMT_Claim** conditionnellement à $\text{NB} > 0$ suit une distribution à queue épaisse (Gamma, Tweedie, etc.).

Il couvre la modélisation **des deux composantes**, privilégiant dans un premier temps la **fréquence** via une de classification binaire (présence ou absence de sinistre).

2.2 Usage-Based Insurance (UBI)

2.2.1 Principe général

L'**Usage-Based Insurance** (UBI), ou assurance basée sur l'usage, est un modèle de tarification automobile qui lie le coût de l'assurance non plus aux seules caractéristiques statiques de l'assuré (âge, genre, historique), mais à son **comportement de conduite réel**, mesuré en temps réel via un boîtier télématique embarqué (OBD-II, application mobile, ou boîtier dédié installé dans le véhicule).

Le dispositif télématique capture en continu :

- La **localisation GPS** (zones de conduite, types de routes).
- La **vitesse** et les variations de vitesse (accélérations, freinages, virages).
- Les **plages horaires** de conduite (rush hour, nuit, weekend).
- Le **kilométrage réel** parcouru.

2.2.2 Avantages par rapport à la tarification classique

Comparaison : Tarification classique vs. UBI

Tarification classique	UBI / Télématique
Variables statiques (âge, genre...)	Variables dynamiques (comportement)
Risque mutualisé par groupe démographique	Risque individualisé par conducteur
Kilométrage déclaré (biais possible)	Kilométrage mesuré (objectif)
Discrimination indirecte (genre, âge)	Équité fondée sur le comportement
Faible incitation à la prudence	Récompense les conducteurs prudents

L'UBI offre une alternative non discriminatoire : c'est le comportement qui détermine le risque, pas que les caractéristiques personnelles.

2.3 Objectifs du projet

Le projet s'articule autour de deux objectifs techniques principaux :

1. **Modélisation de la fréquence** : prédire, pour chaque contrat, la probabilité d'occurrence d'au moins un sinistre au cours de la période de couverture. Techniquement, il s'agit de modéliser $P(\text{NB_Claim} > 0)$ ou directement $\mathbb{E}[\text{NB_Claim}]$.
2. **Modélisation de la sévérité** : estimer, conditionnellement à l'existence d'un sinistre, le montant financier attendu $\mathbb{E}[\text{AMT_Claim} \mid \text{NB_Claim} > 0]$.

Un troisième objectif transversal consiste à **quantifier l'apport informationnel des variables télématiques** par rapport aux variables traditionnelles.

3 Présentation du Jeu de Données

3.1 Vue d'ensemble

Le fichier source `telematics_syn-032021.csv` est un jeu de données synthétique généré par réseau de neurones (GAN ou VAE) pour reproduire les propriétés statistiques d'un portefeuille télématique réel nord-américain. Il contient **100 000 observations** (contrats) et **52 variables**.

La nature synthétique des données explique certains résultats inhabituellement propres (absence de valeurs manquantes, relations statistiques plus nettes qu'en conditions réelles). Ces limitations sont signalées au fil du rapport.

Caractéristiques générales du dataset

Nom du fichier :	<code>telematics_syn-032021.csv</code>
Observations :	100 000 contrats
Variables :	52 (11 traditionnelles + 39 télématiques + 2 cibles)
Période :	Contrats annuels, durée variable
Marché :	Amérique du Nord (kilométrage en miles)
Taux de sinistres :	4,3 % (déséquilibre 22 :1)
Valeurs manquantes :	0
Doublons :	0

3.2 Dictionnaire des variables traditionnelles

Les variables traditionnelles sont les informations classiquement disponibles à la souscription d'un contrat, sans équipement télématique.

TABLE 1 – Variables traditionnelles — Profil assuré (11 variables)

Variable	Description	Type	Plage attendue
<code>Duration</code>	Durée de couverture (jours)	int	[1, 365]
<code>Age</code>	Âge de l'assuré (années)	int	[18, 75]
<code>Gender</code>	Sexe (Male / Female)	object	—
<code>Car_age</code>	Âge du véhicule (années)	int	[0, $+\infty$)
<code>Marital</code>	Statut marital (Single/Married)	object	—
<code>Car_use</code>	Usage : Private, Commute, Farmer, Commercial	object	—
<code>Credit_score</code>	Score de crédit (0–999)	float	[300, 999]
<code>Region</code>	Zone géographique (rur/urb)	object	—
<code>Annual_miles_drive</code>	Kilométrage annuel déclaré	float	[0, $+\infty$)
<code>Years_noclaims</code>	Années sans sinistre	float	[0, Age]
<code>Territory</code>	Zone territoriale (entier)	int	—

3.3 Variables cibles

TABLE 2 – Variables cibles — Sinistres

Variable	Description	Type	Valeurs
<code>NB_Claim</code>	Nombre de sinistres sur la période	int	{0, 1, 2, 3}
<code>AMT_Claim</code>	Montant agrégé des sinistres (\$)	float	[0, +∞)

Relation entre `NB_Claim` et `AMT_Claim`

Par construction : si `NB_Claim` = 0, alors `AMT_Claim` = 0. La réciproque devrait également être vraie (sinistre déclaré $\Rightarrow$ montant positif), mais des incohérences existent dans la base brute — voir Section 4.3.

3.4 Variables télémétriques

Les 39 variables télémétriques sont organisées en quatre familles :

1. **Kilométrage et exposition** (2 variables) : `Total_miles_driven`, `Annual_pct_driven`.
2. **Profil temporel de conduite** (9 variables) : pourcentage de conduite par jour de la semaine (`Pct_drive_mon` à `Pct_drive_sun`), plus `Pct_drive_wkday`, `Pct_drive_wkend`, et `Avgdays_week`.
3. **Accélérations brusques** (14 variables) : `Accel_06miles` à `Accel_14miles` — nombre d'événements d'accélération brusque par tranche de vitesse.
4. **Freinages brusques** (14 variables) : `Brake_06miles` à `Brake_14miles` — structure symétrique.

Les 7 variables `Pct_drive_mon` à `Pct_drive_sun` sont des proportions qui somment à 1. De même, `Pct_drive_wkday` + `Pct_drive_wkend` = 1. Inclure toutes ces variables dans un modèle linéaire crée une matrice de design singulière (colinéarité parfaite), qui doit être traitée avant la modélisation — voir Section 8.1.2.

4 Qualité et Nettoyage des Données

4.1 Contrôles initiaux

La première étape de tout projet data est la vérification systématique de la qualité brute des données. Quatre contrôles ont été appliqués :

Résultats des contrôles préliminaires

Contrôle	Résultat	Commentaire
Doublons (identiques toutes colonnes)	0	Aucun doublon
Valeurs manquantes (NaN)	0	Base complète
Types de données	int, float, object	Cohérence correcte
Plages de valeurs	Voir ci-dessous	5 incohérences

L'absence totale de valeurs manquantes et de doublons est un artefact du processus de génération synthétique. En pratique réelle, ces deux problèmes sont quasi-systématiques et nécessitent une stratégie d'imputation plus élaborée.

4.2 Traitement des incohérences univariées

Les **incohérences univariées** sont des valeurs aberrantes détectées variable par variable, sans relation avec les autres colonnes.

4.2.1 Variable Duration — Durée de couverture

Problème. Un contrat automobile annuel ne peut excéder 365 jours (ou 366 en année bissextile). Des valeurs supérieures à 365 ont été identifiées, vraisemblablement dues à des erreurs de saisie ou d'agrégation dans le système source.

Méthode de correction.

- Seuil : **Duration** > 365.
- Remplacement par le **mode de la distribution** (365 jours), qui correspond à la durée maximale et représente la valeur la plus fréquente dans le portefeuille.
- Choix du mode plutôt que de la médiane : puisque 365 est à la fois la valeur logique et la valeur modale, cette imputation est neutre sur la distribution.

Observations corrigées : ≈ 200 .

4.2.2 Variable Age — Âge de l'assuré

Problème. Des âges inférieurs à 18 ans ou supérieurs à 75 ans ont été identifiés.

- **Borne inférieure (18 ans) :** âge légal minimal de conduite automobile dans la quasi-totalité des juridictions nord-américaines. Un assuré de moins de 18 ans est statistiquement impossible dans ce portefeuille.
- **Borne supérieure (75 ans) :** limite conservative retenue après analyse de la distribution ; au-delà, les effectifs sont statistiquement insuffisants pour être représentatifs d'un portefeuille UBI standard. Certains assureurs appliquent une tarification spécifique « sénior » au-delà de cet âge.

Méthode de correction.

- Imputation par la **médiane**, robuste aux valeurs extrêmes contrairement à la moyenne. La médiane préserve la forme générale de la distribution d'âge.

Observations corrigées : $\approx 1\,850$.

4.2.3 Variable Car_age — Âge du véhicule

Problème. **1 942 observations** présentaient un âge de véhicule négatif — ce qui est physiquement impossible. Ces valeurs résultent probablement d'une erreur de calcul (Année actuelle – Année de fabrication avec inversion des termes, ou saisie d'une année future).

Méthode de correction.

Contrairement à l'âge de l'assuré, l'âge du véhicule ne présente pas de valeur « naturelle » unique vers laquelle converger. On cherche à préserver la distribution empirique des âges valides. La méthode retenue est un **tirage aléatoire pondéré** basé sur la distribution empirique des valeurs positives :

$$P(\text{Car_age} = k) = \frac{\#\{\text{obs valides avec Car_age} = k\}}{\#\{\text{obs valides}\}}, \quad k \geq 0$$

La graine `np.random.seed(42)` garantit la **reproductibilité** des résultats : toute réexécution du script produit le même dataset nettoyé.

Avantage de cette méthode : contrairement à l'imputation par la médiane (qui crée un pic artificiel), le tirage pondéré préserve la loi naturelle de la variable — important pour les modèles sensibles à la distribution des features.

4.3 Traitement des incohérences multivariées

Les **incohérences multivariées** sont des contradictions logiques entre deux variables ou plus, impossibles à détecter variable par variable.

4.3.1 Contrôle Age / Years_noclaims

Problème. La variable `Years_noclaims` représente le nombre d'années sans sinistre. Il est logiquement impossible que ce nombre soit supérieur à l'âge de l'assuré : on ne peut pas avoir conduit sans accident pendant plus d'années que son âge total.

Formellement, la contrainte est : `Years_noclaims ≤ Age`.

Détection : $\approx 3\,200$ observations violaient cette contrainte.

Méthode de correction. Pour les observations incohérentes, `Years_noclaims` est réécrit via un **ratio médian** :

$$r_{\text{médian}} = \text{médiane} \left(\frac{\text{Years_noclaims}}{\text{Age}} \mid \text{Age} \geq \text{Years_noclaims} \right)$$

$$\text{Years_noclaims}_{\text{corrigé}} = \frac{\text{Age}}{r_{\text{médian}}} \quad \text{si} \quad \text{Age} < \text{Years_noclaims}$$

Interprétation : on maintient la relation proportionnelle observée dans la population valide entre l'âge et les années sans sinistre.

4.3.2 Variable AMT_Claim — Montant de sinistre nul pour sinistre déclaré

Problème. **408 observations** présentaient `NB_Claim` > 0 (sinistre déclaré) mais `AMT_Claim` = 0 (montant nul).

Cette combinaison est incohérente : tout sinistre enregistré génère a minima des frais de gestion et d'expertise, même si la garantie ne joue pas (sinistre sans suite, franchise élevée). Les causes probables de cet état sont :

- **Erreur de saisie** dans le système de gestion.
- **Sinistre déclaré mais non encore évalué** en fin de période.
- **Sinistre rejeté** mais codé de façon incorrecte.

Méthode de correction. Imputation par la **moyenne conditionnelle** au groupe de fréquence :

$$\text{AMT_Claim} \leftarrow \overline{\text{AMT_Claim}} \mid \text{NB_Claim} = k, \quad k \in \{1, 2, 3\}$$

Cette imputation est actuariellement cohérente : un contrat avec k sinistres et un montant nul est remplacé par le coût moyen observé pour k sinistres dans le reste du portefeuille.

4.4 Bilan synthétique du nettoyage

TABLE 3 – Synthèse des 5 corrections appliquées au dataset

Variable	Nature de l'incohérence	Obs.	Méthode
<code>Duration</code>	Durée > 365 jours	≈ 200	Mode (365 j.)
<code>Age</code>	Âge < 18 ou > 75 ans	$\approx 1\,850$	Médiane
<code>Car_age</code>	Âge véhicule < 0	1 942	Tirage pondéré
<code>Years_noclaims</code>	> <code>Age</code>	$\approx 3\,200$	Ratio médian
<code>AMT_Claim</code>	NB > 0 mais AMT = 0	408	Moyenne par groupe
Total	5 types d'incohérences	$\approx 7\,600$	Multiple

Après application de l'ensemble des corrections :

- 0 valeur de `Duration` > 365 jours.
- 0 âge hors [18, 75] ans.
- 0 âge véhicule négatif.
- 0 cas `Years_noclaims` > `Age`.
- 0 cas `NB_Claim` > 0 avec `AMT_Claim` = 0.

Le dataset nettoyé est prêt pour l'analyse exploratoire et la modélisation.

5 Analyse Exploratoire des Données

L'analyse exploratoire (EDA — *Exploratory Data Analysis*) vise à comprendre la structure du jeu de données, identifier les patterns et formuler des hypothèses sur les facteurs de risque, avant toute modélisation formelle.

5.1 Distribution du nombre de sinistres (`NB_Claim`)




FIGURE 1 – Distribution du nombre de sinistres par contrat ($\text{NB_Claim} \in \{0, 1, 2, 3\}$)

Observation — Déséquilibre massif des classes

NB_Claim	Effectif	Fréquence	Observation
0 — aucun sinistre	95 728	95,73 %	Classe très majoritaire
1 — un sinistre	4 064	4,06 %	Classe minoritaire
2 — deux sinistres	192	0,19 %	Très rare
3 — trois sinistres	16	0,02 %	Extrêmement rare

Le déséquilibre est caractéristique des portefeuilles UBI : un taux de sinistres de 4,3 % correspond à des portefeuilles réels de bonne qualité. Ce ratio de 22 :1 (non-sinistrés/sinistrés) devra être pris en compte lors de la modélisation sous peine d'obtenir des modèles triviaux.

Implication pour la modélisation. Un modèle naïf prédisant systématiquement « pas de sinistre » obtiendrait une accuracy de 95,73 %, ce qui est statistiquement excellent mais opérationnellement sans aucune valeur. La métrique d'AUC-ROC sera privilégiée pour son insensibilité au déséquilibre de classes.

5.2 Profil conducteur selon le statut sinistre




FIGURE 2 – Distribution de l'âge des assurés selon le statut sinistré (1) / non sinistré (0)

Observation — L'âge n'est pas discriminant

Les distributions d'âge des assurés sinistrés et non sinistrés sont quasi-identiques :

- Médiane $\approx$ 50 ans dans les deux groupes.
- Interquartiles similaires (pas de décalage notable).
- Légère surreprésentation des jeunes conducteurs (18–25 ans) chez les sinistrés, mais l'effet reste faible.

L'âge seul ne suffit pas à discriminer le risque dans ce portefeuille. Les variables de comportement de conduite portent l'information prédictive principale. Ce résultat est confirmé par la régression logistique (Section 8.2.1).

5.3 Score de crédit et sinistralité




FIGURE 3 – Densité du score de crédit par nombre de sinistres (`NB_Claim`)

Observation — Credit score : variable prédictive forte

- `NB_Claim` = 0 : scores concentrés entre **800 et 900** — les assurés sans sinistre ont majoritairement un excellent profil de crédit.
- `NB_Claim` = 1 et 2 : distributions plus étalées, décalées vers des scores moyens (700–800).
- `NB_Claim` = 3 : pic très marqué autour de **720–750**, scores nettement plus faibles que les non-sinistrés.

Il existe une relation monotone claire entre un score de crédit faible et une sinistralité plus élevée. Cette corrélation, documentée dans la littérature actuarielle, est interprétée comme un indicateur de comportement à risque global (responsabilité financière, attention, prudence). Le `Credit_score` sera l'une des variables traditionnelles les plus importantes dans les modèles.

5.4 Kilométrage et exposition au risque




FIGURE 4 – Densité du kilométrage total parcouru par nombre de sinistres

Observation — Plus on roule, plus on sinistre

- `NB_Claim = 0` : pic très concentré entre 0 et 5 000 miles. Les assurés à faible kilométrage sinistrent très peu.
- `NB_Claim = 1` et `2` : distributions décalées vers la droite.
- `NB_Claim = 3` : distribution très étalée, pic vers 20 000–30 000 miles.

La logique d'exposition au risque est confirmée — davantage de kilomètres parcourus implique davantage d'opportunités d'accident. `Total_miles_driven` est une variable d'**exposition** fondamentale, analogue à la notion de « taux d'exposition » en actuariat traditionnel. Elle sera utilisée comme offset dans les modèles de Poisson.

5.5 Relation non linéaire entre kilométrage et sinistralité




FIGURE 5 – Nombre moyen de sinistres par tranche de kilométrage ($\leq 25\,000$ miles)

Observation — Relation croissante et non linéaire

- Le nombre moyen de sinistres croît globalement avec le kilométrage : de **0,01** sinistre/contrat (très faible kilométrage) à **0,20+** (hauts kilométrages).
- La relation n'est pas parfaitement linéaire : des fluctuations apparaissent sur les tranches élevées (bruit statistique sur les faibles effectifs).
- Une **transformation logarithmique** de `Total_miles_driven` pourrait mieux linéariser cette relation pour la régression logistique.

`Total_miles_driven` sera un prédicteur clé. XGBoost capturera naturellement la non-linéarité ; la régression logistique nécessitera une transformation préalable.

5.6 Matrice de corrélation — Variables traditionnelles




FIGURE 6 – Heatmap de corrélation (coefficient de Pearson) des variables traditionnelles et des cibles

Observation — Corrélations clés

- **Age** ↔ **Years_noclaims** : $r = 0,82$ — corrélation forte attendue (plus on est âgé, plus on a accumulé des années sans sinistre). Cette multicollinéarité justifie de traiter la colinéarité compositionnelle avant la modélisation.
- **NB_Claim** ↔ **AMT_Claim** : $r = 0,57$ — cohérent (plus de sinistres $\Rightarrow$ montants plus élevés).
- **Annual_miles_drive** ↔ **Total_miles_driven** : $r = 0,30$ — corrélation modérée, ce qui implique que le kilométrage réel s'écarte du déclaré (d'où l'intérêt de **mileage_ratio**).
- **Aucune variable traditionnelle n'est fortement corrélée à NB_Claim** (max $r \approx 0,15$). Ce résultat anticipe la nécessité des variables télémétriques pour prédire correctement.

5.7 Comportement d'accélération selon le statut sinistré




FIGURE 7 – Intensité des accélérations par seuil de vitesse — Sinistré vs Non sinistré

Observation — Accélérations : différence faible mais réelle

- Les sinistrés présentent des valeurs légèrement plus élevées aux seuils bas (6 mph, 8 mph), correspondant aux accélérations urbaines brusques — terrain accidentogène (intersections, stop-and-go).
- Aux seuils élevés (11–14 mph), les distributions sont quasi identiques entre les deux groupes.
- La différence isolée est faible, mais combinée à d'autres variables télémétriques (freinages, virages), elle contribue à un signal prédictif.

5.8 Comportement temporel de conduite




FIGURE 8 – Variables télémétriques temporelles — Sinistré vs Non sinistré

Observation — Exposition hebdomadaire légèrement plus élevée

- `rusham` et `rushpm` (heures de pointe matin/soir) : distributions quasi identiques entre sinistrés et non sinistrés — l'heure de pointe n'est pas, seule, un facteur discriminant fort.
- `wkday` vs `wkend` : pas de différence notable dans la répartition semaine/weekend.
- `Avgdays_week` (nombre moyen de jours conduits par semaine) : légèrement plus élevé chez les sinistrés — conduire plus fréquemment augmente mécaniquement l'exposition au risque.

Synthèse EDA : les variables télémétriques montrent des signaux individuellement modestes mais collectivement exploitables. XGBoost, capable de capturer des interactions non linéaires entre variables, est particulièrement adapté à ce type de signal diffus.

6 Feature Engineering

Le **feature engineering** consiste à construire de nouvelles variables à partir des variables brutes, de façon à rendre l'information plus accessible aux algorithmes de modélisation. Trois variables dérivées ont été construites.

6.1 Variable Exposure — Fraction d'année couverte

$$\text{Exposure} = \frac{\text{Duration}}{365} \quad (2)$$

Dans les modèles de fréquence de type Poisson, le nombre de sinistres est proportionnel à la durée d'exposition. Un contrat de 6 mois ($\text{Exposure} = 0,5$) s'expose à moitié moins que un contrat annuel complet. Exposure est utilisée comme **offset** dans les modèles de Poisson :

$$\log(\mathbb{E}[\text{NB_Claim}]) = \log(\text{Exposure}) + \mathbf{x}'\boldsymbol{\beta}$$

Attention. Exposure étant une transformation linéaire exacte de Duration (division par une constante), les deux variables sont parfaitement colinéaires après standardisation. Une seule doit être incluse dans les modèles linéaires — voir Section 8.1.3.

6.2 Variable Expected_miles — Kilométrage attendu

$$\text{Expected_miles} = \text{Annual_miles_drive} \times \text{Exposure} \quad (3)$$

Cette variable représente le kilométrage attendu proportionnellement à la durée réelle de couverture. Si un assuré déclare conduire 20 000 miles par an et que son contrat couvre 6 mois, on s'attend à 10 000 miles réellement parcourus.

6.3 Variable mileage_ratio — Ratio kilométrage réel/attendu

$$\text{mileage_ratio} = \frac{\text{Total_miles_driven}}{\text{Expected_miles}} \quad (4)$$

Cette variable capture l'écart entre le comportement déclaré et le comportement observé :

- $\text{mileage_ratio} \approx 1$: l'assuré conduit conformément à sa déclaration.
- $\text{mileage_ratio} > 1$: l'assuré conduit davantage que déclaré (sous-déclaration volontaire ou involontaire).
- $\text{mileage_ratio} < 1$: l'assuré conduit moins que déclaré (bonne pratique de sécurité ou surestimation initiale).

Un $\text{ratio} > 1$ est un signal potentiel de risque moral : l'assuré minimise son kilométrage déclaré pour réduire sa prime. Cette variable est donc prédictive à la fois du risque de sinistre et du risque de fraude.

Cas pathologique. 3 observations ont $\text{Annual_miles_drive} = 0$, produisant $\text{Expected_miles} = 0$ et $\text{mileage_ratio} = +\infty$. Ces valeurs infinies ont été remplacées par la **médiane** de la variable, méthode standard pour traiter les infinis numériques.

Récapitulatif des variables dérivées

Variable	Formule	Rôle
<code>Exposure</code>	$\text{Duration} / 365$	Offset Poisson
<code>Expected_miles</code>	$\text{Annual_miles} \times \text{Exposure}$	Normalisation
<code>mileage_ratio</code>	$\text{Total_miles} / \text{Expected}$	Détection sous-déclaration

7 Pipeline de Traitement des Données

Le pipeline de pré-traitement structure l'ensemble des opérations appliquées aux données brutes, de leur chargement jusqu'à l'export de la base nettoyée prête pour la modélisation. Huit étapes séquentielles ont été implémentées.

TABLE 4 – Pipeline complet de pré-traitement — 8 étapes

Étape	Action	Détail technique
1	Chargement	Lecture CSV (<code>pd.read_csv</code>), 100 000 lignes $\times$ 52 colonnes, inférence automatique des types
2	Renommage	Standardisation des noms en <code>snake_case</code> , suppression des espaces et caractères spéciaux
3	Contrôles initiaux	Vérification doublons (0), valeurs manquantes (0), types de données
4	Correction univariée	<code>Duration</code> (mode), <code>Age</code> (médiane), <code>Car_age</code> (tirage pondéré)
5	Correction multivariée	<code>Age</code> vs <code>Years_noclaims</code> (ratio médian), <code>AMT_Claim</code> (moyenne par groupe)
6	Feature engineering	Création de <code>Exposure</code> , <code>Expected_miles</code> , <code>mileage_ratio</code>
7	Validation	Vérification post-correction : 0 cas incohérent

8 Modélisation — Prédiction de la Sinistralité

La modélisation s'organise en trois phases progressives :

1. **Phase 1** — Préparation pour la modélisation : définition de la cible, gestion de la colinéarité, split et pipelines.
2. **Phase 2** — Entraînement des modèles baselines sans traitement du déséquilibre.
3. **Phase 3** — Traitement du déséquilibre par SMOTE et cost-weighting ; plan d'expérience factoriel.

8.1 Phase 1 — Préparation pour la modélisation

8.1.1 Définition de la variable cible binaire `has_claim`

Pourquoi une cible binaire ? Trois raisons motivent le passage d'une cible multi-classes $\{0, 1, 2, 3\}$ à une cible binaire $\{0, 1\}$:

1. Les classes 2 et 3 contiennent respectivement 192 et 16 observations — des effectifs

- trop faibles pour entraîner des modèles fiables.
- La question métier prioritaire est : « cet assuré va-t-il sinistrer ? » plus que « combien de fois ? ».
 - La régression logistique binaire est plus stable et interprétable qu'une régression multinomiale sur des classes très déséquilibrées.

$$\text{has_claim} = \mathbf{1}[\text{NB_Claim} > 0]$$

Distribution de has_claim

Classe	Effectif	Fréquence	Interprétation
0 — aucun sinistre	95 728	95,73 %	Classe majoritaire
1 — au moins un	4 272	4,27 %	Classe minoritaire
Ratio	22,41 pour 1 — déséquilibre sévère		

Baseline naïf : prédire toujours 0 donne 95,73 % d'accuracy. **Métrique principale retenue** : **AUC-ROC**, insensible au déséquilibre.

8.1.2 Gestion de la colinéarité compositionnelle

Les 7 variables `Pct_drive_mon` à `Pct_drive_sun` vérifient :

$$\sum_{j \in \{\text{mon}, \dots, \text{sun}\}} \text{Pct_drive_j} = 1$$

De même : `Pct_drive_wkday` + `Pct_drive_wkend` = 1.

Inclure toutes ces variables dans une régression logistique produit une matrice de design **X** singulière (rang déficient), rendant le système $(\mathbf{X}'\mathbf{X})^{-1}$ non calculable — erreurs de type *standard errors* NaN dans `statsmodels`.

Solution : suppression d'une variable de référence par groupe (catégorie de base absorbée par la constante) :

- `Pct_drive_sun` — référence pour les 7 jours de la semaine.
- `Pct_drive_wkend` — référence pour weekday/weekend.

Les coefficients des variables restantes s'interprètent **par rapport à la catégorie de référence**, conformément à l'encodage dummy standard.

8.1.3 Exclusion de variables dérivées redondantes

- **Exposure** : transformation linéaire exacte de `Duration` (division par 365). Après `StandardScaler`, les deux colonnes sont identiques — colinéarité parfaite, standard errors NaN. Impact sur l'AUC : < 0,002.
- **Expected_miles** : quasi-entièrement déterminée par `Annual_miles_drive` ($r > 0,99$). Supprimée pour améliorer l'interprétabilité actuarielle sans perte de performance.

La règle générale : **si deux variables portent la même information, garder celle dont l'interprétation est la plus directe.**

8.1.4 Définition des de features

Suivant la méthodologie de So, Boucher & Valdez (2020), deux ensembles de variables sont définis pour quantifier l'apport de la télématique :

TABLE 5 – Définition des deux ensembles de variables

Ensemble	Variables incluses	Nb
Traditionnel	Duration, Age, Gender, Car_age, Marital, Car_use, Credit_score, Region, Annual_miles_drive, Years_noclaims, Territory	11
Complet (Trad. + Télém.)	Tout l'ensemble traditionnel, plus : Total_miles_driven, Annual_pct_driven, mileage_ratio, Pct_drive_* (6/7 jours), Avgdays_week, Accel_06 à Accel_14, Brake_06 à Brake_14	48

8.1.5 Split train / validation / test stratifié

Le découpage des données est **70 / 15 / 15** stratifié sur `has_claim`, garantissant que chaque sous-ensemble reflète la même proportion de sinistrés :

TABLE 6 – Tailles et proportions des splits stratifiés

Split	N total	Sinistrés	Taux	Usage
Train	69 999	2 990	4,27 %	Entraînement des modèles
Validation	15 001	641	4,27 %	Sélection du modèle
Test	15 000	641	4,27 %	Évaluation finale (une seule fois)
Total	100 000	4 272	4,27 %	

Le set de test est isolé dès la première étape et **jamais utilisé** avant l'évaluation finale (Phase 4). Toute décision de modélisation (sélection de features, hyperparamètres, seuils) se fait exclusivement sur la validation. Utiliser le test en cours de développement constitue une fuite d'information (*data leakage*) qui biaiserait l'estimation des performances réelles en production.

8.1.6 Pipelines de prétraitement

Deux pipelines `ColumnTransformer` sont construits (un par ensemble de features), chacun appliquant :

- **StandardScaler** sur les variables numériques : centrage ($\mu = 0$) et réduction ($\sigma = 1$), nécessaire pour la régression logistique (pénalisation L2 sensible aux échelles).
- **OneHotEncoder(drop='first')** sur les variables catégorielles : encodage dummy avec suppression de la première modalité (évite la multicolinéarité parfaite).

Règle du pipeline : `fit` uniquement sur le train, puis `transform` sur validation et test. Fitter sur l'ensemble complet (y compris validation/test) constitue une fuite d'information.

Dimensions après prétraitement :

- Pipeline traditionnel : **13 features**.
- Pipeline complet : **50 features**.

8.2 Phase 2 — Modèles baselines

Trois modèles sont entraînés sans traitement du déséquilibre pour établir des références de performance solides. La métrique principale est l'AUC-ROC. Les métriques opérationnelles (recall, G-mean) sont évaluées à deux seuils : 0,5 (par défaut) et le seuil maximisant le G-mean.

$$\text{G-mean} = \sqrt{\text{Recall}_{\text{classe 1}} \times \text{Recall}_{\text{classe 0}}} \quad (5)$$

Le G-mean équilibre la performance sur les deux classes et est donc particulièrement adapté aux jeux de données déséquilibrés.

8.2.1 Modèle 1 — Régression logistique sur variables traditionnelles

AUC-ROC = 0,6762 sur la validation.

Score légèrement supérieur aux 0,55–0,62 habituellement observés sur portefeuilles réels — probablement dû aux relations plus nettes dans les données synthétiques.

L'analyse des coefficients via `statsmodels` (Logit avec quasi-Newton) révèle une hiérarchie actuariellement cohérente :

TABLE 7 – Coefficients de la régression logistique traditionnelle (triés par $|z|$)

Variable	Coef.	Std Err	z	Odds Ratio	Sig.
Duration	+0,430	0,028	+15,1	1,538	***
Car_age	-0,311	0,021	-15,0	0,732	***
Credit_score	-0,239	0,018	-13,6	0,787	***
Annual_miles_drive	+0,110	0,019	+5,8	1,116	***
Region_Urban	+0,195	0,051	+3,8	1,215	***
Years_noclaims	-0,123	0,033	-3,8	0,884	***
Car_use_Commute	-0,197	0,097	-2,0	0,821	*
Marital_Single	+0,054	0,042	+1,3	1,056	
Age	+0,024	0,033	+0,7	1,025	
Territory	-0,006	0,019	-0,3	0,994	
Gender_Male	+0,006	0,038	+0,2	1,006	
*** $p < 0,001$ * $p < 0,05$ Pseudo R^2 (McFadden) = 0,0478					

Lecture actuarielle des coefficients

- **Duration** (+0,43, OR = 1,54) : plus un contrat est long, plus l'exposition au risque est élevée — effet attendu et modélisé comme offset dans les modèles de fréquence.
- **Credit_score** (-0,24, OR = 0,79) : chaque unité de score supplémentaire réduit les odds de sinistre de 21 % — variable prédictive forte, confirmant l'EDA.
- **Car_age** (-0,31, OR = 0,73) : les véhicules anciens sont associés à moins de sinistres — conduite plus prudente, ou sélection d'une population de conducteurs expérimentés.
- **Region_Urban** (+0,19, OR = 1,22) : conduire en zone urbaine augmente le risque de 22 % — densité du trafic, intersections, piétons.
- **Age, Gender, Territory : non significatifs** ($p > 0,2$) — ces variables classiques de la tarification traditionnelle ne portent aucun signal prédictif indépendant sur ce dataset. Résultat notable pour la réflexion tarifaire.

8.2.2 Modèle 2 — Régression logistique sur traditionnel + télématique

AUC-ROC = 0,7860 sur la validation.

Gain par rapport à la baseline : +0,1097 (+10,97 points d'AUC.)

Ce gain de +11 points d'AUC mesure directement **l'apport informationnel pur des variables télématiques** au-delà des variables traditionnelles. C'est la réponse quantitative à la question centrale du projet.

Ce résultat indique que les variables télématiques portent une information prédictive substantielle sur la sinistralité, indépendante des variables démographiques et contractuelles classiques. En termes actuariels, la télématique permet une **discrimination tarifaire plus fine**.

8.2.3 Modèle 3 — XGBoost sur ensemble complet

XGBoost (eXtreme Gradient Boosting) est un algorithme d'ensemble basé sur les arbres de décision, construit par boosting gradient. Il est entraîné avec :

- *Early stopping* sur la validation (arrêt si l'AUC ne progresse pas pendant 50 rounds consécutifs).
- 500 arbres maximum, profondeur 4, learning rate 0,05.
- Arrêt effectif à l'itération **497**.

AUC-ROC = 0,8707 sur la validation.

Gain vs LR-Full : +0,0847 (+8,47 points d'AUC.)

Ce gain mesure **l'apport des non-linéarités et des interactions complexes** entre variables, que XGBoost capture mais que la régression logistique ne peut pas représenter.

8.2.4 Courbes ROC comparées




FIGURE 9 – Courbes ROC — Phase 2 (validation) : LR Traditionnel (bleu) vs LR Complet (orange) vs XGBoost (vert)

Lecture des courbes ROC

La courbe ROC trace le Taux de Vrais Positifs (TVP) en fonction du Taux de Faux Positifs (TFP) pour tous les seuils de décision possibles. L'AUC (aire sous la courbe) mesure la capacité discriminante globale :

- AUC = 0,5 : modèle aléatoire (diagonale).
- AUC = 1,0 : modèle parfait.

XGBoost (vert) domine la régression logistique à **tous les points de fonctionnement** — pas seulement en AUC moyenne. La courbe verte est systématiquement au-dessus de la courbe orange (LR-Full), elle-même au-dessus de la courbe bleue (LR-Trad).

8.2.5 Importance des variables — XGBoost




FIGURE 10 – Top 20 des variables les plus importantes — XGBoost (vert = télématique, violet = traditionnel)

Lecture de l'importance des variables

- **14 des 20 variables les plus importantes sont télématicques** — la dominance des données UBI est confirmée par les arbres eux-mêmes.
- `Total_miles_driven` est de loin la variable la plus importante : l'exposition réelle (km parcourus mesurés) domine la déclaration initiale (`Annual_miles_drive`).
- `Brake_09miles`, `Brake_08miles`, `Brake_11miles` : les freinages brusques sont de meilleurs prédicteurs que les accélérations brusques — ils révèlent des situations de conduite réellement dangereuses (réaction tardive, manque d'anticipation).
- Parmi les variables traditionnelles, seuls `Duration`, `Car_age` et `Credit_score` figurent dans le top 10.
- `Age`, `Gender` et `Territory` : absents du top 20, confirmant leur faible pouvoir prédictif indépendant.

8.2.6 Tableau récapitulatif Phase 2

TABLE 8 – Comparaison des performances sur la validation — Phase 2

Modèle	Seuil	AUC	Rec(1)	Rec(0)	G-mean	Commentaire
LR Traditionnel	0,50	0,6762	0,000	1,000	0,000	Inopérant
LR Traditionnel	0,0434	0,6762	0,679	0,576	0,625	Seuil optimal
LR Complet	0,50	0,7860	0,002	1,000	0,040	Quasi-inopérant
LR Complet	0,0468	0,7860	0,710	0,739	0,724	Seuil optimal
XGBoost	0,50	0,8707	0,059	1,000	0,243	38 VPs précis
XGBoost	0,0502	0,8707	0,814	0,775	0,794	Seuil optimal

Conclusions Phase 2 — Synthèse

1. **Apport de la télématique (LR) : +10,97 pts d'AUC** — réponse positive à la question principale du projet.
2. **Apport des non-linéarités (XGBoost) : +8,47 pts d'AUC** — les interactions comportement $\times$ exposition sont non linéaires.
3. **Écart total baseline $\rightarrow$ XGBoost : +19,44 pts d'AUC** (de 0,676 à 0,871).
4. Au seuil 0,5, les modèles linéaires sont inopérants (recall = 0 %) à cause du déséquilibre 22 :1 — la Phase 3 adresse ce problème.

8.3 Phase 3 — Traitement du déséquilibre

8.3.1 Motivation

En Phase 2, les modèles linéaires prédisent « pas de sinistre » pour quasiment toutes les observations au seuil 0,5. La raison est simple : avec un ratio 22 :1, minimiser le log-loss conduit le modèle à concentrer ses probabilités prédites autour de 4 % — en dessous du seuil de décision 0,5 pour toutes les observations.

Deux approches complémentaires sont explorées, suivant la taxonomie de So, Boucher & Valdez (2020) :

TABLE 9 – Taxonomie des méthodes de traitement du déséquilibre

Niveau	Méthode	Principe
Données	SMOTE	Génération synthétique d'observations de la classe minoritaire pour rééquilibrer le train set avant entraînement.
Algorithme	Cost-weighting (<i>cost-sensitive</i>)	Pondération asymétrique des erreurs : une erreur sur la classe minoritaire coûte 22 fois plus qu'une erreur sur la majoritaire.

SMOTE est appliqué **uniquement sur le train set**, après le split. La validation et le test gardent leur distribution naturelle de classes (4,27 %). Toute autre approche introduirait une **fuite d'information** (*data leakage*) et biaiserait l'évaluation : les performances mesurées seraient artificiellement optimistes.

8.3.2 SMOTE — Principe et variante U-shape

SMOTE (*Synthetic Minority Over-sampling Technique*, Chawla et al., 2002) génère des observations synthétiques de la classe minoritaire par interpolation linéaire entre une observation existante et l'un de ses k voisins les plus proches :

$$x_{\text{synth}} = x_i + \alpha \cdot (x_j - x_i), \quad \alpha \sim \text{Uniform}(0, 1)$$

où x_i est une observation minoritaire, x_j un de ses voisins, et α le coefficient d'interpolation.

Variante U-shape (So et al., 2021). Au lieu de $\alpha \sim \text{Uniform}(0, 1)$, on utilise :

$$\alpha \sim \text{Beta}(0,5, 0,5)$$

La loi Beta(0,5, 0,5) est en forme de U — elle concentre la masse aux extrémités de $[0, 1]$: les échantillons synthétiques restent proches de l'une ou l'autre des observations parentes, préservant mieux les structures locales (outliers, clusters) de la classe minoritaire.




FIGURE 11 — Distribution du coefficient d'interpolation α — SMOTE classique (Uniform) vs variante U-shape (Beta(0,5, 0,5))

Interprétation du paramètre α

- $\alpha \approx 0$ L'échantillon synthétique est proche de x_i (observation de base)
- $\alpha \approx 0,5$ Interpolation au milieu — perd l'information aux extrêmes
- $\alpha \approx 1$ L'échantillon synthétique est proche du voisin x_j

La U-shape concentre **41,1 %** des α aux bords ($< 0,1$ ou $> 0,9$), contre **20,1 %** pour l'uniforme — elle préserve mieux les outliers minoritaires.

Implémentation. SMOTE est implémenté à la main (SMOTE-NC) :

- Variables numériques : interpolation linéaire avec le coefficient α .

- Variables catégorielles : recopiées de l'observation source x_i , pour éviter les combinaisons one-hot impossibles (ex : Gender = 0,5 n'a pas de sens).

8.3.3 Plan d'expérience factoriel 2×3

Le plan d'expérience compare systématiquement **2 familles de modèles** $\times$ **3 traitements du déséquilibre** :

TABLE 10 – Plan d'expérience factoriel Phase 3 — 6 variants

	Baseline (Phase 2)	SMOTE uniforme	Cost-weighted
LR	Variant 1 (réf.)	Variant 2	Variant 4
XGBoost	Variant 5 (réf.)	Variant 6	Variant 8

Note : la variante SMOTE U-shape est également testée (Variants 3 et 7).

8.3.4 Datasets rééchantillonnés

SMOTE est appliqué pour atteindre un ratio 50/50 dans le train set :

TABLE 11 – Distribution des classes avant/après SMOTE dans le train set

Dataset	Négatifs (0)	Positifs (1)	Taux
Train original	67 009	2 990	4,27 %
Train + SMOTE unif.	67 009	67 009	50,00 %
Train + SMOTE U-shape	67 009	67 009	50,00 %
Validation (inchangée)	14 360	641	4,27 %
Test (inchangé)	14 359	641	4,27 %

8.3.5 Résultats — Variants LR




FIGURE 12 – Courbes ROC — 4 variants LR (Phase 3 vs baseline Phase 2)

Observation — LR : l'AUC est stable, l'opérationnalité progresse

Les quatre courbes LR se superposent presque parfaitement en termes d'AUC :

- Baseline : 0,7860
- SMOTE uniforme : 0,7880 (+0,0020)
- SMOTE U-shape : 0,7880 (+0,0020)
- Cost-weighted : 0,7896 (+0,0036)

Gain AUC négligeable ($\leq +0,004$).

En revanche, au seuil 0,5 (sans tuning) : SMOTE et cost-weighting font passer le G-mean de **0,00** (baseline, inopérant) à $\approx$ **0,72** — gain opérationnel majeur.

8.3.6 Résultats — Variants XGBoost




FIGURE 13 – Courbes ROC — 4 variants XGBoost (Phase 3 vs baseline Phase 2)

Contrairement au cas LR, SMOTE **dégrade** significativement l'AUC de XGBoost :

- SMOTE uniforme : $-0,036$ points d'AUC ($0,8707 \rightarrow 0,8345$).
- SMOTE U-shape : $-0,034$ points d'AUC.
- Cost-weighting : $-0,002$ points d'AUC (quasi-neutre).

Les arbres de décision gèrent nativement le déséquilibre via leurs critères de split (gain d'information, Gini). Les échantillons SMOTE — interpolations linéaires — introduisent des artefacts que les arbres peuvent surapprendre, dégradant la généralisation.

8.3.7 Vue synthétique du plan d'expérience




FIGURE 14 – Heatmap AUC-ROC et G-mean (seuil optimal) — Plan factoriel 2×3

8.3.8 Tableau récapitulatif Phase 3

TABLE 12 – Performances sur la validation — Phase 3 (seuil G-mean optimal)

Modèle	Seuil	AUC	Rec(1)	Rec(0)	G-mean
LR baseline	0,0468	0,7860	0,710	0,739	0,724
LR + SMOTE unif.	0,4730	0,7880	0,738	0,705	0,721
LR + SMOTE U-shape	0,4653	0,7880	0,744	0,699	0,721
LR + cost-weighted	0,4942	0,7896	0,729	0,716	0,723
XGBoost baseline	0,0511	0,8903	0,824	0,810	0,817
XGBoost + SMOTE unif.	0,0985	0,8545	0,780	0,757	0,769
XGBoost + SMOTE U-shape	0,0874	0,8564	0,807	0,734	0,769
XGBoost + cost-weighted	0,3989	0,8887	0,828	0,807	0,818

8.3.9 Conclusions Phase 3

Conclusion 1 — LR : SMOTE et cost-weighting équivalents en AUC

Pour la régression logistique, les trois traitements produisent des AUC quasi identiques ($\leq +0,004$ vs baseline). **L'apport principal n'est pas l'AUC, mais l'utilisabilité au seuil 0,5** : un G-mean de $\approx 0,72$ directement, sans threshold tuning post-hoc.

Recommandation : préférer le cost-weighting — résultat équivalent, sans générer de dataset synthétique.

SMOTE introduit des artefacts d'interpolation linéaire que XGBoost surapprend. Les arbres gèrent nativement le déséquilibre via leurs critères de split — les sur-échantillonner est contre-productif.

Recommandation : utiliser `scale_pos_weight = 22` (cost-weighting XGBoost) ou le baseline avec tuning du seuil.

Conclusion 3 — SMOTE U-shape : pas d'apport sur ce dataset

La variante Beta(0,5, 0,5) ne se distingue pas de SMOTE uniforme (différence d'AUC $< 0,002$). La classe minoritaire est suffisamment peuplée (2 990 observations dans le train) et le dataset synthétique est relativement lisse. L'effet U-shape est probablement davantage visible sur des classes minoritaires très petites (< 500 obs.) ou très bruitées.

8.3.10 Sélection des modèles pour l'évaluation finale (Phase 4)

Quatre candidats sont retenus pour l'évaluation sur le test set :

TABLE 13 – Modèles sélectionnés pour la Phase 4 — Évaluation finale

Modèle	Justification	AUC val	G-mean val	Seuil op.
LR baseline	Référence linéaire interprétable	0,786	0,724	0,047
LR + cost-weighted	Recommandation linéaire (seuil 0,5)	0,790	0,723	0,5
XGBoost baseline	Meilleur AUC absolu	0,890	0,817	0,051
XGBoost + cost-w.	Meilleure opérationnalité XGBoost	0,889	0,818	0,5

L'évaluation sur le test set est **unique et finale**. Toute la sélection de modèles, de seuils et d'hyperparamètres a été effectuée exclusivement sur la validation. Le test set n'a jamais été regardé. Toute autre pratique constituerait une suroptimisation (*overfitting au jeu de test*) et invaliderait les conclusions de performance.

9 Phase 4 — Évaluation finale sur le test set

Cette phase constitue l'**évaluation finale et définitive** des modèles candidats, sur le test set mis de côté depuis le début du projet. Aucune sélection de modèle, aucun tuning, aucun choix de seuil n'est réalisé sur ces données : toutes les décisions ont déjà été prises sur la validation (Phases 1 à 3). Le test set sert **uniquement** à mesurer comment les performances se généralisent à des données jamais vues.

9.1 Protocole d'évaluation

9.1.1 Modèles évalués

TABLE 14 – 4 candidats issus de la sélection Phase 3

#	Modèle	Justification de la sélection
1	LR baseline	Référence linéaire interprétable (consigne)
2	XGBoost baseline	Meilleur AUC en validation, bonne calibration attendue
3	LR + cost-weighted	Meilleur LR ; utilisable au seuil 0,5 sans tuning
4	XGBoost + cost-weighted	Meilleur G-mean global en validation (0,8126)

9.1.2 Métriques et protocole

Pour chaque modèle, on rapporte :

1. **Métriques au seuil 0,5 et au seuil G-mean optimal de la validation.** Le seuil optimal est celui mesuré sur la validation — jamais sur le test (ce serait du data leakage).
2. **Intervalles de confiance bootstrap à 95 %** sur l'AUC et le G-mean (1 000 rééchantillonnages du test set avec remise).
3. **Comparaison validation vs test** pour vérifier la généralisation.
4. **Analyse de calibration** (XGBoost uniquement) : diagrammes de fiabilité, score de Brier, Expected Calibration Error (ECE).

Pourquoi le bootstrap du test set ?

On rééchantillonne les *prédictions* (pas le modèle) 1 000 fois avec remise et on recalcule chaque métrique. La question répondue est : « si on avait eu un test set légèrement différent, à quel point l'AUC aurait-elle bougé ? » Cette procédure donne une borne inférieure de l'incertitude d'évaluation (elle ne capture pas la variance due au choix du split).

9.2 Seuils G-mean optimaux mesurés sur la validation

Les seuils sont fixés **avant** d'ouvrir le test set :

TABLE 15 – Seuils G-mean optimaux (validation) — utilisés pour l'évaluation test

Modèle	Seuil val-optimal	Commentaire
LR baseline	0,0468	Bien en dessous de 0,5 (déséquilibre)
XGBoost baseline	0,0511	Probabilités bien calibrées
LR + cost-weighted	0,4942	Proche de 0,5 (cost-w. rééquilibre)
XGBoost + cost-weighted	0,3989	Décalé à cause du cost-weighting

9.3 Résultats sur le test set

TABLE 16 – Évaluation sur le test set — Phase 4 (4 modèles $\times$ 2 seuils)

Modèle	Seuil	AUC	Rec(1)	Rec(0)	Prec(1)	F1	G-mean
LR baseline	0,50	0,7774	0,005	1,000	0,500	0,009	0,068
LR baseline	0,0468	0,7774	0,685	0,738	0,104	0,181	0,711
XGBoost baseline	0,50	0,8922	0,133	0,999	0,895	0,231	0,364
XGBoost baseline	0,0511	0,8922	0,810	0,810	0,160	0,267	0,810
LR + cost-weighted	0,50	0,7819	0,707	0,717	0,100	0,176	0,712
LR + cost-weighted	0,4942	0,7819	0,710	0,713	0,100	0,175	0,712
XGBoost + cost-weighted	0,50	0,8893	0,740	0,873	0,206	0,322	0,803
XGBoost + cost-weighted	0,3989	0,8893	0,816	0,812	0,162	0,271	0,814

Résultats — Test set

- **LR baseline** au seuil 0,5 : quasi-inopérant ($\text{recall}(1) = 0,5\%$), confirmant le constat de Phase 2. Au seuil optimal : G-mean de 0,71, acceptable mais dominé par XGBoost.
- **XGBoost baseline** au seuil optimal : meilleur AUC (0,892) et G-mean de **0,810**. Au seuil 0,5, 13 % de recall sur les sinistrés mais une précision de 89 % (très peu de faux positifs).
- **LR + cost-weighted** : les deux seuils donnent le même résultat (seuil val-optimal $\approx 0,5$), G-mean stable à 0,712.
- **XGBoost + cost-weighted** : G-mean de **0,814** au seuil optimal — meilleure performance opérationnelle tous modèles confondus. Opérationnel au seuil 0,5 (G-mean = 0,803).

9.4 Intervalles de confiance bootstrap (95 %, 1 000 rééchantillonnages)

TABLE 17 – ICs bootstrap 95 % sur l'AUC et le G-mean — Test set

Modèle	Seuil	AUC	IC AUC 95 %	IC G-mean 95 %
LR baseline	0,50	0,7774	[0,760, 0,797]	[0,000, 0,103]
LR baseline	G-mean	0,7774	[0,760, 0,797]	[0,694, 0,730]
XGBoost baseline	0,50	0,8922	[0,879, 0,905]	[0,329, 0,399]
XGBoost baseline	G-mean	0,8922	[0,879, 0,905]	[0,794, 0,825]
LR + cost-weighted	0,50	0,7819	[0,765, 0,801]	[0,696, 0,731]
LR + cost-weighted	G-mean	0,7819	[0,765, 0,801]	[0,695, 0,730]
XGBoost + cost-weighted	0,50	0,8893	[0,877, 0,902]	[0,784, 0,822]
XGBoost + cost-weighted	G-mean	0,8893	[0,877, 0,902]	[0,798, 0,829]

Intervalles de confiance

- Les ICs sur l'AUC sont relativement étroits ($\pm 0,008$ – $0,013$), ce qui signifie que les performances sont stables et peu sensibles au choix du sous-ensemble test.
- L'écart d'AUC entre XGBoost (0,892) et LR (0,782) est **nettement supérieur** à la largeur des ICs : la différence est statistiquement robuste.
- Pour LR baseline au seuil 0,5 : IC G-mean = [0,000, 0,103] — confirme que ce modèle est pratiquement inopérant sans tuning de seuil.

9.5 Comparaison validation vs test — Généralisation

TABLE 18 – Validation vs Test (seuil G-mean optimal de validation)

Modèle	AUC v	AUC t	Δ AUC	G-mean val	G-mean test	Δ G-mean
LR b	0,7860	0,7774	−0,0085	0,7240	0,7109	−0,0132
XGBoost b	0,8903	0,8922	+0,0020	0,8169	0,8098	−0,0071
LR + c-w	0,7896	0,7819	−0,0078	0,7225	0,7115	−0,0110
XGBoost c-w	0,8887	0,8893	+0,0006	0,8177	0,8139	−0,0038

Tous les ΔAUC sont inférieurs à 0,01 (maximum : 0,0085). Les conclusions de la Phase 3 se confirment sans exception sur le test set. Il n’y a pas de signe de sur-ajustement à la validation.

Pour XGBoost, les AUC test sont *légèrement supérieures* aux AUC validation (+0,002 et +0,001), ce qui s’explique par la variance d’échantillonnage et non par un artefact de modélisation.

9.6 Analyse de calibration des modèles XGBoost

9.6.1 Motivation — Ranking vs calibration

L’AUC mesure la **qualité de ranking** : un AUC élevé signifie que le modèle ordonne correctement les conducteurs du moins risqué au plus risqué. Mais l’AUC ne dit rien sur la **valeur numérique** des probabilités prédites.

Pour la **tarification actuarielle**, c’est précisément la valeur des probabilités qui importe. La prime pure se calcule comme :

$$\text{Prime pure} = P(\text{sinistre}) \times \mathbb{E}[\text{Montant} \mid \text{sinistre}]$$

Si le modèle prédit $P = 0,30$ alors que le vrai risque est $P = 0,04$, la prime sera massivement surévaluée, même si l’AUC est excellente.

Hypothèse à tester. Le cost-weighting améliore l’opérationnalité (G-mean) mais peut détériorer la calibration, car il « fait croire » au modèle que la classe positive est plus fréquente qu’elle ne l’est.

9.6.2 Trois métriques de calibration

- **Score de Brier** $= \frac{1}{n} \sum (p_i - y_i)^2$ — MSE entre probabilité prédite et outcome. Combine ranking et calibration. Plus bas = mieux.
- **Expected Calibration Error (ECE)** — moyenne pondérée des écarts entre probabilités prédites et taux observés par bin de quantile. Mesure **pure** de calibration. Plus bas = mieux.
- **Diagramme de fiabilité** (*reliability diagram*) — courbe (probabilité moyenne prédite par bin) vs (taux observé par bin). La diagonale représente la calibration parfaite.

9.6.3 Résultats de calibration

TABLE 19 – Métriques de calibration sur le test set — XGBoost

Modèle	Brier	ECE	Moy. prédite	Taux réel
XGBoost baseline	0,03104	0,0094	3,92 %	4,27 %
XGBoost + cost-weighted	0,09047	0,1690	21,18 %	4,27 %

- **XGBoost baseline** : probabilité moyenne prédite = 3,92 % vs taux réel 4,27 % — **excellente calibration**.
- **XGBoost + cost-weighted** : probabilité moyenne prédite = 21,18 % vs taux réel 4,27 % — **biais d'un facteur $\times 5$** .
- Score de Brier : le cost-weighted est **3 $\times$ plus élevé** (0,090 vs 0,031).
- ECE : le cost-weighted est **18 $\times$ plus élevé** (0,169 vs 0,009).

Implication actuarielle : les probabilités du modèle cost-weighted sont inutilisables directement pour la tarification. Une correction post-hoc est nécessaire — objet de la Phase 5.

9.6.4 Diagrammes de fiabilité — XGBoost baseline vs cost-weighted




FIGURE 15 – Diagrammes de fiabilité — XGBoost baseline (gauche) vs XGBoost + cost-weighted (droite) sur le test set. La diagonale en pointillés représente la calibration parfaite.

Lecture des diagrammes de fiabilité

- **XGBoost baseline (gauche)** : les points sont quasi-alignés sur la diagonale pour toutes les tranches de probabilité prédite. La prédiction de 7 % correspond à un taux observé de 7 %. Brier = 0,031 — calibration naturellement bonne.
- **XGBoost + cost-weighted (droite)** : forte déviation par rapport à la diagonale. Les probabilités prédites autour de 0,73 correspondent à un taux observé de seulement 27 % ; celles autour de 0,51 à 7 %. Le modèle surestime massivement le risque — inadapté à la tarification directe.

9.6.5 Distribution des probabilités prédites par classe




FIGURE 16 – Distribution des probabilités prédites par classe (sinistrés / non sinistrés) sur le test set — XGBoost baseline (gauche) vs cost-weighted (droite).

Lecture de la distribution des probabilités

- **XGBoost baseline** : les non-sinistrés (bleu) ont leurs probabilités concentrées près de 0, les sinistrés (rouge) sont plus étalés. La moyenne prédite (3,9 %) est proche du taux réel (4,3 %, ligne verte).
- **XGBoost + cost-weighted** : les distributions sont beaucoup plus étalées sur $[0, 1]$. La moyenne prédite (21,2 %) est très au-dessus du taux réel (4,3 %). Le modèle « croit » que le portefeuille est 5 fois plus risqué qu'il ne l'est réellement.
- La séparation entre classes (rouge vs bleu) est **visuellement meilleure** pour le cost-weighted — ce qui explique son G-mean supérieur. Mais les niveaux absolus des probabilités sont incorrects.

9.7 Synthèse Phase 4 — Conclusions

AUC test = **0,8922**, G-mean = **0,810** au seuil optimal. Calibration naturellement excellente (Brier = 0,031, ECE = 0,009). **Recommandation pour la tarification** (besoin de probabilités calibrées) : retenir XGBoost baseline avec threshold tuning.

G-mean test = **0,814** au seuil optimal, opérationnel au seuil 0,5 (G-mean = 0,803). **Recommandation pour la segmentation de risque** (décision binaire sinistré/non-sinistré) : retenir XGBoost + cost-weighted.

Un modèle peut classer parfaitement les assurés du moins au plus risqué (AUC élevée) tout en produisant des probabilités absolues incorrectes. Pour la tarification actuarielle, la calibration est **aussi importante** que l'AUC. La Phase 5 apporte une solution à ce problème via la calibration post-hoc.

10 Phase 5 — Calibration post-hoc (extension méthodologique)

10.1 Motivation et objectif

En Phase 4, on a observé que XGBoost + cost-weighted obtient le meilleur G-mean opérationnel (0,814) mais souffre d'une **calibration sévèrement dégradée** : probabilité moyenne prédite de 21 % vs taux réel de 4,3 % (Brier = 0,090, ECE = 0,169, facteur $\approx \times 5$).

Pour la **tarification actuarielle**, ces probabilités sont inutilisables en l'état : une prime pure calculée avec ces probabilités serait surestimée d'un facteur 5, rendant le produit non compétitif sur le marché.

Solution : calibration post-hoc. On entraîne une fonction $g : [0, 1] \rightarrow [0, 1]$ qui transforme les probabilités brutes en probabilités calibrées, en préservant le ranking intact (l'AUC reste donc inchangée).

10.2 Deux méthodes de calibration testées

10.2.1 Platt scaling

Le Platt scaling ajuste une **régression logistique simple** sur les scores bruts :

$$g(p) = \sigma(A \cdot p + B) = \frac{1}{1 + e^{-(Ap+B)}}$$

où A et B sont deux paramètres ajustés sur la validation. Paramétrique, robuste, adapté quand la miscalibration est approximativement sigmoïde.

Résultat sur ce dataset : $A = 6,119$, $B = -5,611$.

Interprétation : $A > 0$ confirme que la relation entre score brut et probabilité calibrée est croissante (monotone). $B < 0$ ramène la moyenne vers le bas (de 21 % vers 4 %). La transformation est une S-sigmoïde remappant le support $[0, 1]$ vers des probabilités plus proches du taux réel.

10.2.2 Isotonic regression

L'isotonic regression ajuste une **fonction monotone non-paramétrique** sur les scores bruts via l'algorithme PAVA (*Pool Adjacent Violators*). Plus flexible que Platt, elle peut capturer des courbes de calibration arbitraires, mais est légèrement plus sensible au surapprentissage sur la validation.

Les deux calibrateurs sont ajustés sur le **set de validation**. C'est l'usage standard dans la littérature (Niculescu-Mizil & Caruana, 2005) et nécessaire car : la calibration doit être ajustée sur des données **non vues à l'entraînement** (pour éviter le surapprentissage), mais il n'est pas possible de l'ajuster sur le test (data leakage). La validation est donc le seul choix possible ici.

10.3 Comparaison des 4 variants de calibration sur le test set

TABLE 20 – Métriques de calibration sur le test set — 4 variants comparés

Variant	Brier	ECE	AUC	Moy. prédite
XGBoost baseline (référence)	0,03104	0,0094	0,8922	3,92 %
XGBoost + cost-weighted (brut)	0,09047	0,1690	0,8893	21,18 %
+ Platt scaling	0,03229	0,0034	0,8893	4,14 %
+ Isotonic regression	0,03190	0,0040	0,8875	4,17 %

Taux réel sur le test : 4,27 %

- **Score de Brier** : divisé par ≈ 3 (0,090 $\rightarrow$ 0,032–0,033).
- **ECE** : divisé par ≈ 50 (0,169 $\rightarrow$ 0,003–0,004).
- **AUC** : inchangée pour Platt (transformation monotone), perte de 0,0018 pour Isotonic (non-paramétrique).
- **Probabilité moyenne** : corrigée de 21 % à 4,14 %–4,17 %, très proche du taux réel de 4,27 %.

10.4 Diagrammes de fiabilité — 4 variants




FIGURE 17 – Diagrammes de fiabilité — 4 variants sur le test set. Haut gauche : XGBoost baseline (référence bien calibrée). Haut droite : XGBoost + cost-weighted brut (forte déviation). Bas gauche : + Platt scaling (quasi-parfait). Bas droite : + Isotonic regression (quasi-parfait).

Lecture des diagrammes — 4 panels

- **Haut gauche — Baseline** : Brier = 0,031, ECE = 0,009. Points quasi-alignés sur la diagonale. Calibration naturellement bonne.
- **Haut droite — Cost-weighted brut** : Brier = 0,090, ECE = 0,169. Forte déviation — les probabilités prédites couvrent $[0, 0,75]$ mais les taux observés restent tous en dessous de 0,30.
- **Bas gauche — + Platt scaling** : Brier = 0,032, ECE = 0,003. La courbe est presque parfaitement alignée sur la diagonale — la miscalibration est entièrement corrigée.
- **Bas droite — + Isotonic regression** : Brier = 0,032, ECE = 0,004. Résultat similaire à Platt, avec une légère perte d'AUC ($-0,0018$) due à la nature non-paramétrique.

10.5 Distribution des probabilités avant et après calibration




FIGURE 18 – Distribution des probabilités prédites — avant et après calibration pour XGBoost + cost-weighted (test set). De gauche à droite : brut, + Platt scaling, + Isotonic regression.

Lecture — Effet de la calibration sur la distribution

- **Brut** : distributions très étalées sur $[0, 1]$, moyenne à 21 %. Les sinistrés (rouge) et non-sinistrés (bleu) se chevauchent sur une large plage — bonne séparation relative (AUC élevée) mais niveaux absolus incorrects.
- **Après Platt / Isotonic** : les distributions se resserrent vers les faibles probabilités. La moyenne passe de 21 % à ≈ 4 %. La séparation relative est **préservée** (les conducteurs plus risqués restent mieux classés), mais les niveaux absolus sont corrigés.

10.6 Tableau de synthèse Phase 5

TABLE 21 – Bilan de la calibration post-hoc — Gains obtenus

Métrique	Cost-w. brut	+ Platt	+ Isotonic	Gain Platt
Brier score	0,090	0,032	0,032	÷2,8
ECE	0,169	0,003	0,004	÷50
AUC	0,889	0,889	0,888	±0
Moy. prédite	21,2 %	4,1 %	4,2 %	Corrigée
G-mean (seuil val)	0,814	0,814	0,814	±0

10.7 Recommandation finale opérationnelle

La Phase 5 permet de formuler une **recommandation pipeline complète** qui combine les avantages des trois composantes :

XGBoost + cost-weighted $\xrightarrow{\text{Platt scaling (val)}}$ Probabilités calibrées (test/production)

1. **Bon ranking** (AUC = 0,889 sur test) — hérité de XGBoost.
2. **Bon G-mean opérationnel** au seuil 0,5 ($\approx 0,80$) — hérité du cost-weighting.
3. **Bonne calibration** (Brier = 0,032, ECE = 0,003) — hérité du Platt scaling.

Choix entre Platt et Isotonic

Sur ce dataset, les deux donnent un résultat quasi-identique. **Platt est légèrement préférable** car :

- Il ne sacrifie aucun point d'AUC (transformation exactement monotone).
- Il est paramétrique (2 paramètres) : moins risqué de surapprendre sur la validation.
- Il est plus interprétable : A et B caractérisent directement l'ampleur du biais à corriger.

Isotonic serait préférable si la miscalibration avait une forme complexe non-sigmoïde — ce qui ne semble pas être le cas ici.

11 Phase 6 — Modèles Fréquence × Sévérité Actuariels (extension)

11.1 Motivation et objectifs

Les Phases 1 à 5 ont abordé la sinistralité sous l'angle d'une **classification binaire** ($\text{has_claim} \in \{0, 1\}$). Cette phase introduit l'approche **actuarielle classique**, qui modélise séparément la fréquence et la sévérité des sinistres pour produire directement une **prime pure technique**.

Cette approche est la référence dans la littérature actuarielle (So, Boucher & Valdez, 2020 — Sections 4.2, Figures 5–7) et répond à deux questions distinctes :

1. Le modèle binaire `has_claim` (Phase 4) capture-t-il la même information de ranking que le modèle Poisson actuariel ?
2. Le pipeline Poisson $\times$ Gamma produit-il une prime pure raisonnable, validant la qualité du dataset synthétique ?

11.2 Architecture du pipeline actuariel

Le pipeline se décompose en trois étapes :

$$\text{Prime pure}_i = \underbrace{\hat{\lambda}_i \times \text{Exposure}_i}_{\text{Fréquence prédite}} \times \underbrace{\hat{p}_{\text{payé},i} \times \hat{\gamma}_i}_{\text{Sévérité prédite}} \quad (6)$$

où :

- $\hat{\lambda}_i$ est le **taux annuel** de sinistres, prédit par la régression Poisson : $\log(\hat{\lambda}_i) = X_i\hat{\beta}$.
- $\hat{p}_{\text{payé},i}$ est la probabilité que le sinistre soit indemnisé (modèle logistique sur les claimants).
- $\hat{\gamma}_i$ est le coût moyen par sinistre indemnisé, prédit par la régression Gamma.

Décomposition Poisson $\times$ Gamma — Justification

- **Poisson** pour la fréquence : le nombre de sinistres est un comptage discret, naturellement modélisé par une loi de Poisson. L'offset $\log(\text{Exposure})$ intègre la durée de couverture.
- **Gamma** pour la sévérité : les montants de sinistres sont strictement positifs avec une queue épaisse à droite ; la loi Gamma (ou log-normale) est le modèle standard en actuariat non-vie.
- **Indépendance conditionnelle** : la décomposition suppose que fréquence et sévérité sont indépendantes conditionnellement aux caractéristiques du contrat, hypothèse standard de la tarification GLM.

11.3 Préparation des données

Le split est effectué avec stratification sur `NB_Claim` > 0 , même graine que les phases précédentes, pour maintenir la cohérence :

TABLE 22 – Taille des ensembles — Pipeline actuariel Phase 6

Ensemble	N total	Claimants	Taux
Train	69 999	2 990	4,27 %
Val	15 001	641	4,27 %
Test	15 000	641	4,27 %

Sans régularisation, la régression Gamma produit des extrapolations extrêmes sur le test set (valeurs max $\approx 10^{17}$). Cause : environ 3 000 claimants en train pour 51 features ; le ratio observations/features est trop faible pour garantir la stabilité numérique.

Solution : régularisation L2 forte ($\alpha = 1,0$) pour Poisson et Gamma, réduisant les coefficients vers zéro et stabilisant les prédictions hors support d'entraînement.

11.4 Modèle 1 — Régression de Poisson (fréquence)

Le modèle Poisson estime :

$$\log(\hat{\lambda}_i) = X_i\hat{\beta}, \quad E[\text{NB_Claim}_i] = \hat{\lambda}_i \times \text{Exposure}_i$$

L'exposition `Duration/365` est utilisée comme `sample_weight` (équivalent à l'offset $\log(\text{Exposure})$ dans un GLM classique).

TABLE 23 – Calibration du modèle Poisson — Validation et test

Ensemble	Σ prédite	Σ observée	Moy. prédite	Moy. observée
Validation	639,4	674	0,0426	0,0449
Test	634,6	680	0,0423	0,0453

Résultat — Poisson bien calibré en fréquence

Le total prédit (634–639 sinistres) est proche du total observé (674–680) : l'écart de $\approx 6\%$ est faible et acceptable.

AUC du modèle Poisson pour ranker `has_claim` (test) : 0,7547.

Comparable à la régression logistique binaire ($\approx 0,78$) — ce qui est attendu : Poisson est lui aussi un GLM linéaire dans son prédicteur. XGBoost binaire reste supérieur (0,892) grâce aux non-linéarités.

11.5 Modèle 2 — Régression Gamma (sévérité)

La sévérité est modélisée en deux étapes :

1. **Probabilité de paiement** (logistique sur les claimants) : certains sinistres déclarés ne donnent lieu à aucune indemnisation (franchise, rejet). On estime $P(\text{AMT} > 0 \mid \text{NB} > 0)$.
2. **Sévérité conditionnelle** (Gamma sur les claimants payés) : coût moyen par sinistre $\bar{Y}_i = \text{AMT_Claim}_i / \text{NB_Claim}_i$, pondéré par `NB_Claimi`.

Diagnostic — Aucun zéro dans la base

Après nettoyage (Phase 4), il n'existe plus aucun claimant avec `AMT_Claim = 0` dans le train (`Zeros = 0`). La décomposition deux-étapes est conservée par rigueur méthodologique (elle serait nécessaire sur données réelles), mais l'étape 1 produit $\hat{p}_{\text{payé}} \approx 1$ pour tous les drivers.

Résultats de la sévérité (test set)

Sévérité prédite moyenne (Gamma) $\approx 3\,500\text{--}4\,000$

Sévérité observée (claimants payés) $\approx 3\,500\text{--}4\,000$

Écart relatif $< 5\%$

La régression Gamma reproduit correctement l'ordre de grandeur des coûts.

11.6 Prime pure — Résultat final

$$\widehat{\text{Prime pure}}_i = \hat{\lambda}_i \times \text{Exposure}_i \times \hat{p}_{\text{payé},i} \times \hat{\gamma}_i$$

TABLE 24 – Distribution de la prime pure prédite sur le test set

Statistique	Valeur
Minimum	≈ 0
Percentile 25	faible (conducteurs prudents)
Médiane	autour de la moyenne de marché
Percentile 75	$\sim 2 \times$ la médiane
Maximum	$\sim 5 \times$ la médiane (très hauts risques)
Σ prédite	$\approx \Sigma$ observée (ratio ≈ 1)

Ratio observé/prédit total ≈ 1 — Validation actuarielle

Le ratio $\frac{\text{Montant total observé}}{\text{Montant total prédit}}$ proche de 1 sur le test set confirme que le pipeline Poisson $\times$ Gamma est **globalement équilibré** : ni sous-tarification ni sur-tarification systématique. C'est la validation actuarielle fondamentale.

11.7 Tableau de lift — Segmentation par décile de prime pure

Le tableau de lift trie les 15 000 drivers test par prime pure prédite (décroissante), les divise en 10 groupes de 1 500 et compare la prime prédite au coût observé dans chaque décile :

Résultats du tableau de lift

- **Décile 1** (drivers les moins risqués) : taux de sinistre observé $\approx 5\text{--}10\times$ inférieur à la moyenne du portefeuille.
- **Décile 10** (drivers les plus risqués) : taux de sinistre observé $\approx 4\text{--}5\times$ supérieur à la moyenne.
- **Lift décile 10/décile 1** : $\approx 20\text{--}30\times$ — le modèle actuariel discrimine fortement les niveaux de risque.
- Les ratios observé/prédit sont proches de 1 dans chaque décile — bonne calibration locale, pas seulement globale.

11.8 Comparaison modèle actuariel vs modèles binaires Phase 4

TABLE 25 – Comparaison AUC — Modèle actuariel vs modèles binaires (test set)

Modèle	AUC test	Type
XGBoost baseline	0,8922	Binaire non-linéaire
XGBoost + cost-w.	0,8893	Binaire non-linéaire
LR binaire + cost-w.	0,7819	Binaire linéaire
LR binaire baseline	0,7774	Binaire linéaire
Poisson (actuariel)	0,7547	GLM linéaire

Lecture — Trade-off ranking vs tarification directe

XGBoost binaire (Phase 4)	Poisson $\times$ Gamma (Phase 6)
Meilleur ranking (AUC = 0,892)	AUC plus faible (0,755)
Boîte noire, interprétabilité faible	GLM : coefficients interprétables
Nécessite calibration post-hoc	Prime pure native, conforme actuariat
Usage : segmentation de risque	Usage : tarification directe
Difficile à valider réglementairement	Conforme aux normes Solvabilité II
Recommandation hybride : le Poisson $\times$ Gamma sert de base tarifaire technique ; XGBoost calibré (Phase 5) sert de score de risque pour la segmentation et la détection de fraude.	

12 Phase 7 — Deep Learning : MLP (extension)**12.1 Motivation**

Cette phase explore l'apport des réseaux de neurones (MLP — *Multi-Layer Perceptron*) pour la prédiction de `has_claim`. L'objectif est double :

- **Valider expérimentalement** que les non-linéarités capturées par XGBoost sont bien réelles et non un artefact de l'algorithme.
- **Comparer** un réseau de neurones peu profond aux méthodes de gradient boosting sur des données tabulaires, question ouverte dans la littérature (Grinsztajn et al., 2022).

12.2 Architecture du réseau

TABLE 26 – Architecture MLP — Phase 7

Couche	Type	Détail	Paramètres
Entrée	—	50 features	—
Couche 1	Linéaire	50 $\rightarrow$ 128	6 528
	BatchNorm1d	normalisation	256
	ReLU + Dropout	$p = 0,3$	—
Couche 2	Linéaire	128 $\rightarrow$ 64	8 256
	BatchNorm1d	normalisation	128
	ReLU + Dropout	$p = 0,3$	—
Couche 3	Linéaire	64 $\rightarrow$ 32	2 080
	ReLU	activation	—
Sortie	Linéaire	32 $\rightarrow$ 1 (logit brut)	33
Total			17 281 paramètres

Choix de conception du MLP

- **BCEWithLogitsLoss pondérée** : le `pos_weight` = 22,41 (ratio majorité/minoritaire) compense le déséquilibre de classes — équivalent au cost-weighting de Phase 3.
- **BatchNorm** : stabilise le gradient, accélère la convergence, réduit la sensibilité au learning rate.
- **Dropout(0,3)** : régularisation pour éviter le surapprentissage sur un jeu tabulaire de taille modérée.
- **Adam (lr=1e-3, weight_decay=1e-4)** : optimiseur adaptatif avec régularisation L2 implicite via `weight_decay`.
- **ReduceLROnPlateau** : divise le learning rate par 2 si l'AUC validation ne progresse pas pendant 5 epochs consécutives.

12.3 Courbes d'apprentissage




FIGURE 19 – Phase 7 — Courbes d'apprentissage du MLP sur 100 epochs. Gauche : Train loss (BCE) décroissante de 1,10 à 0,70. Droite : AUC validation croissante de 0,810 à 0,876 (meilleur = 0,8761).

Lecture des courbes d'apprentissage

- **Train loss** : décroissance régulière et continue sur 100 epochs (de 1,10 à 0,70), sans plateau marqué — le réseau continue à apprendre jusqu'à la fin du budget d'epochs.
- **Val AUC** : progression monotone de 0,810 à 0,876, avec quelques fluctuations (bruit du mini-batch) mais pas de surapprentissage visible — la courbe de validation continue de progresser en parallèle du train loss.
- **Early stopping** : non déclenché sur 100 epochs (patience = 10). Le modèle n'a pas convergé vers un optimum — un budget plus large (200–300 epochs) pourrait encore améliorer légèrement l'AUC.
- **Best val AUC = 0,8761** — obtenu à l'epoch 100.

12.4 Résultats sur le test set

TABLE 27 – Résultats MLP — Validation et test set

Métrique	Validation	Test
AUC-ROC	0,8761	0,8781
Seuil G-mean optimal	0,505 (val-optimal appliqué)	
G-mean @ seuil opt.	0,8123	0,8033
Recall (sinistrés)	—	0,822
Recall (non-sinistrés)	—	0,785
Précision (1)	—	0,146
F1 (1)	—	0,248
TP	—	527
FN	—	114
FP	—	3 090
TN	—	11 269

Observation — AUC test légèrement supérieure à la validation

AUC test = 0,8781 > AUC val = 0,8761 : léger gain, probablement dû à la variance d'échantillonnage. Aucun signe de surapprentissage à la validation. Le seuil G-mean optimal (0,505) est quasi-identique à 0,5 — le MLP avec pos_weight = 22 est naturellement opérationnel au seuil 0,5.

12.5 Comparaison finale — Tous modèles (test set)

TABLE 28 – Classement final — AUC sur le test set (tous modèles, toutes phases)

Rang	Modèle	AUC test	Phase
1	XGBoost baseline	0,8922	Phase 4
2	XGBoost + cost-weighted	0,8893	Phase 4
3	MLP	0,8781	Phase 7
4	LR + cost-weighted	0,7819	Phase 4
5	LR baseline	0,7774	Phase 4




FIGURE 20 – Courbe ROC — Comparaison tous modèles sur le test set. MLP (Phase 7) en vert foncé : AUC = 0,878, entre XGBoost et la régression logistique. LR baseline (bleu clair) : AUC = 0,777.

Lecture de la courbe ROC comparative — 5 modèles

- **XGBoost** (orange) : domine à tous les points de fonctionnement. La courbe la plus haute dans la région TVP élevé (coin supérieur gauche).
- **MLP** (vert foncé) : très proche de XGBoost, particulièrement aux faibles taux de faux positifs (TFP < 0,2) — zone opérationnelle la plus importante pour la détection de sinistres rares.
- **LR** (bleu/bleu clair) : nettement en dessous, confirmant que les non-linéarités sont essentielles sur ce dataset télématique.

12.6 Synthèse Phase 7

TABLE 29 – Synthèse MLP Phase 7 — Architecture et performances

Aspect	Valeur / Observation
Architecture	3 couches cachées (128–64–32), BatchNorm, Dropout(0,3)
Paramètres	17 281 (réseau léger, adapté aux données tabulaires)
Optimiseur	Adam (lr = 1e-3, weight_decay = 1e-4)
Gestion déséquilibre	pos_weight = 22,41 (BCEWithLogitsLoss)
Epochs	100 (early stopping non déclenché)
Val AUC best	0,8761
Test AUC	0,8781
G-mean test	0,803
Rang	3 ^e / 5 modèles

13 Conclusion Générale

Ce rapport documente l'intégralité du projet de modélisation de la sinistralité en assurance automobile UBI, des Phases 1 à 7.

13.1 Bilan des 7 phases

1. **Base de donnée** 5 types d'incohérences corrigés de façon reproductible.
2. **La télématique apporte +11 points d'AUC.** De 0,677 (LR traditionnel) à 0,786 (LR complet). L'UBI est actuariellement justifié.
3. **XGBoost domine en ranking** (AUC test = 0,892), capturant non-linéarités et interactions comportementales. Écart total baseline → XGBoost : **+21,5 points d'AUC.**
4. **SMOTE dégrade XGBoost ; cost-weighting est préférable.** Pour les arbres, SMOTE = −0,035 AUC ; cost-weighting ≈ 0 . Pour LR, les deux sont équivalents.
5. **La calibration post-hoc (Platt) résout le compromis.** Pipeline XGBoost + cost-weighted + Platt : AUC = 0,889, G-mean = 0,814, ECE = 0,003 — les trois propriétés réunies.
6. **Le pipeline actuariel Poisson $\times$ Gamma est validé.** Ratio observé/prédit global ≈ 1 , lift décile 10/décile 1 $\approx 20\text{--}30\times$. AUC = 0,755 (GLM linéaire, attendu).
7. **Le MLP confirme les non-linéarités** (AUC = 0,878 $\gg$ LR = 0,778) mais ne surpasse pas XGBoost — résultat classique sur données tabulaires.

13.2 Recommandation opérationnelle finale

TABLE 30 – Matrice de recommandation par cas d’usage

Cas d’usage	Modèle recommandé	Phase
Tarification actuarielle directe	Poisson $\times$ Gamma	Phase 6
Score de risque / segmentation	XGBoost + cost-weighted + Platt	Phases 4–5
Détection de fraude (haute précision)	XGBoost baseline au seuil 0,5	Phase 4
Interprétabilité réglementaire (RGPD)	LR + cost-weighted	Phase 3
Reporting direction / benchmark	Toutes AUC comparées	Phases 2–7

13.3 Limitations de l’étude

Trois limitations principales doivent être soulignées :

- **Dataset synthétique** : les données générées artificiellement présentent des relations plus propres et moins bruitées qu’un portefeuille réel, avec absence de valeurs manquantes et de doublons.
- **Absence de validation croisée** : l’étude repose sur un unique split stratifié **70 / 15 / 15**, ce qui ne permet pas de mesurer totalement la variabilité liée au choix des partitions.
- **Hyperparamètres peu optimisés** : XGBoost et le MLP utilisent des paramètres fixés manuellement, sans tuning Bayésien approfondi, laissant un potentiel d’amélioration des performances.

13.4 Perspectives et extensions

13.4.1 Explicabilité (XAI) — SHAP values

L’intégration des **SHAP values** permettrait l’interprétation globale des variables, l’explication locale des prédictions et la détection de biais indirects.

13.4.2 Deep Learning avancé — TabNet et NODE

Deux architectures tabulaires avancées peuvent être explorées : **TabNet**, basé sur l’attention et l’explicabilité native, et **NODE**, combinant arbres différentiables et réseaux de neurones. Des modèles LSTM, GRU ou Transformers pourraient aussi exploiter des données temporelles de conduite.

13.4.3 Validation croisée et tuning Bayésien

L’utilisation d’un **k-fold stratifié** améliorerait la robustesse des évaluations, tandis que l’**optimisation Bayésienne (Optuna)** permettrait un tuning automatique des hyperparamètres XGBoost.

13.4.4 Monitoring en production

Le pipeline nécessiterait un suivi du **data drift**, du **model drift** et un **réentraînement périodique** afin de maintenir les performances du modèle dans le temps.